



Tecnológico de Monterrey

Análisis y Reporte sobre el desempeño del modelo

K-means

Michelle Rergis Novelo A01798576

16 de Septiembre del 2026

Módulo 2. Inteligencia artificial avanzada para la ciencia de datos.

Profesor: Jorge Adolfo Ramírez Uresti

1. Introducción y Objetivo

El presente reporte analiza el modelo de aprendizaje no supervisado, K-means, implementado en python (con scikit-learn) El objetivo es evaluar qué tan bien generaliza el modelo cuando se aplica a datos reales, más allá del dataset sintético (make_blobs) con el que fue originalmente probado, y determinar si su desempeño puede mejorarse mediante ajuste de hiper parámetros y técnicas de regularización.

Para ello, el modelo se aplicó al dataset real Mall Customer Segmentation Data (Kaggle), que contiene información de 200 clientes de un centro comercial (edad, ingreso anual, puntaje de gasto y género).

2. Separación y evaluación con conjuntos de Train / Validation / Test

A diferencia del script original (que solo dividía en entrenamiento/prueba), en este análisis se agregó un conjunto de validación independiente, usado exclusivamente para seleccionar el número de clusters K y para diagnosticar sesgo/varianza sin tocar el conjunto de prueba final:

Conjunto	Muestras	Proporción	Uso
Entrenamiento	120	60%	Ajuste de K-means y del escalador (StandardScaler)
Validación	40	20%	Selección de K y diagnóstico de sesgo/varianza
Prueba	40	20%	Evaluación final e independiente del modelo

El escalador *StandardScaler* se ajustó únicamente con el conjunto de entrenamiento y se aplicó (*transform*) a validación y prueba, evitando fuga de información (data leakage), tal como en el script original.

Se realizó un barrido de K (2 a 10) evaluando el coeficiente de silueta en los tres conjuntos, entrenando siempre sobre train y prediciendo las etiquetas de validación y prueba con los centroides ya ajustados (K-means permite predict sobre datos no vistos):




Figura 1. Silhouette score vs. K evaluado en entrenamiento, validación y prueba (modelo base, 4 variables, sin regularizar).

El método del codo (sobre el conjunto de entrenamiento) se muestra a continuación como referencia complementaria:




Figura 2. Método del codo (inercia/WCSS) en entrenamiento.

Seleccionando K según el máximo silhouette de VALIDACIÓN se obtiene K=9. Los resultados del modelo final (K-means++, n_init=10) sobre los tres conjuntos fueron:

Métrica	Entrenamiento	Validación	Prueba
Silhouette Score	0.405	0.381	0.410
Inercia (WCSS)	101.12		




Figura 3. Proyección PCA 2D de los clusters asignados en entrenamiento, validación y prueba (modelo base, K=9).

La cercanía entre los tres silhouette scores (0.38–0.41) sugiere que el modelo generaliza razonablemente en cuanto a separación de clusters, pero como se detalla en las secciones siguientes, esta cercanía no implica por sí sola que el modelo sea confiable: hace falta examinar la estabilidad de las asignaciones.

3. Diagnóstico de sesgo (bias)

En K-means el sesgo se manifiesta cuando el modelo es demasiado simple (K muy bajo) para capturar la estructura real de los grupos, produciendo clusters heterogéneos con baja separación interna/externa, de forma consistente tanto en entrenamiento como en validación y prueba.

En la Figura 1 se observa que, para K entre 2 y 4 los tres conjuntos (train, val, test) muestran silhouette bajo y muy similar entre sí (aprox. 0.24–0.35): el modelo subestima el número real de grupos y mezcla segmentos de clientes distintos (por ejemplo, clientes de bajo ingreso/bajo gasto con clientes de bajo ingreso/alto gasto). Esta región es un caso claro de **alto sesgo** (underfitting).

Al usar K=9 (elegido por validación) el silhouette de entrenamiento sube a 0.405, cercano a validación (0.381) y prueba (0.410), lo que indica que **el sesgo del modelo final ya no es el problema dominante**: el modelo sí logra encontrar estructura razonable en los datos. Diagnóstico de sesgo (modelo base, K=9): BAJO A MEDIO. El modelo no está subajustado de forma severa (el silhouette >0.38 en los tres conjuntos y aumenta consistentemente respecto a K bajos), pero el valor absoluto de silhouette (~0.40) sigue siendo modesto, señal de que agregar una variable poco informativa (Gender) impide que el modelo capture toda la estructura disponible en los datos.

4. Diagnóstico de varianza

Para un algoritmo no supervisado como K-means, la varianza se manifiesta como sensibilidad excesiva del resultado (las particiones encontradas) ante cambios pequeños en la inicialización o en la muestra, más que como una diferencia entre error de entrenamiento y error de prueba (que no existe de forma directa al no haber etiqueta objetivo).

Se midió la estabilidad del clustering entrenando el modelo 15 veces con distintas semillas/inicializaciones aleatorias (init="random", n_init=1) para cada K, y calculando el Índice de Rand Ajustado (ARI) promedio entre cada par de corridas. Un ARI cercano a 1 indica que el algoritmo encuentra siempre la misma partición (baja varianza); un ARI bajo indica que la partición depende fuertemente del azar de inicialización (alta varianza):




Figura 4. Estabilidad (ARI promedio entre 15 corridas con distinta inicialización) vs. K , modelo base con 4 variables sin regularizar.

En $K=9$ (el K elegido) el ARI promedio entre corridas es de apenas 0.623 ± 0.113 : en promedio, más de un tercio de los clientes cambian de cluster simplemente al cambiar la semilla aleatoria, aún con el mismo número de clusters y los mismos datos. Con solo 120 muestras de entrenamiento, 4 variables (una de ellas poco informativa) y 9 clusters, el modelo tiene muy pocos puntos por cluster (~ 13 en promedio), lo que lo hace sensible a outliers y a la inicialización.

Diagnóstico de varianza (modelo base, $K=9$): ALTO. La baja estabilidad ante la inicialización ($ARI \approx 0.62$) muestra que el modelo está capturando en buena medida ruido/particularidades de la muestra y de la inicialización, más que estructura robusta y reproducible.

5. Nivel de ajuste del modelo (underfit / fit / overfit)

Combinando los diagnósticos anteriores:

- Para K bajo (2–4): sesgo alto y silhouette bajo y similar entre los tres conjuntos $\rightarrow$ underfitting.
- Para $K=9$ (elegido por validación): sesgo bajo/medio (silhouette razonable y consistente entre train/val/test), pero varianza alta (baja estabilidad ante la

inicialización, $ARI \approx 0.62$) y una relación muestras/parámetros desfavorable (120 muestras, 9 clusters, 4 variables) → señales de sobreajuste (overfitting) impulsado por varianza, no por una brecha grande entre las métricas de entrenamiento y prueba.

Diagnóstico de ajuste (modelo base): OVERFIT (sobreajuste por varianza/inestabilidad). El modelo base no está mal ajustado en el sentido clásico de train vs. test (las tres métricas de silhouette son parecidas), pero sí lo está en el sentido de estabilidad: encuentra demasiados clusters pequeños que dependen del azar de inicialización y de una variable (Gender) que aporta ruido, en lugar de estructura genuina y reproducible.

6. Regularización y ajuste de hiper parámetros

A partir del diagnóstico anterior (alta varianza / sobreajuste por exceso de clusters, ruido de la variable Gender y pocas muestras por cluster), se aplicaron tres cambios:

- **Selección de variables:** se eliminó *Gender_num*, variable categórica binaria que no mostró separación clara entre segmentos y añadía dimensionalidad/ruido innecesarios.
- **Reducción de dimensionalidad** con PCA (2 componentes) sobre *Annual_Income* y *Spending_Score* estandarizados, ajustado únicamente con el conjunto de entrenamiento. Esto actúa como regularización: limita la capacidad efectiva del modelo a la señal más relevante, filtrando ruido.
- Aumento de *n_init* de 10 a 20 (más reinicios de k-means++), lo que reduce la probabilidad de converger a un mínimo local dependiente de una mala inicialización, disminuyendo así la varianza atribuible a la inicialización.

Con estos cambios se repitió el barrido de K en train/validación; el K con mejor silhouette de validación pasó de 9 a 5, un valor mucho más razonable para 120 muestras de entrenamiento:




Figura 5. Silhouette vs. K en entrenamiento y validación, antes (líneas punteadas, 4 variables) y después (líneas sólidas, PCA 2D) de regularizar.

Con K=5 y el modelo regularizado, las métricas finales fueron:

Métrica	Antes (K=9, 4 var.)	Después (K=5, PCA 2D)
Silhouette entrenamiento	0.405	0.557
Silhouette validación	0.381	0.547
Silhouette prueba	0.410	0.537
Inercia (WCSS) entrenamiento	101.12	37.88
Estabilidad (ARI promedio entre 15 corridas)	0.623	0.893




Figura 6. Comparación directa antes vs. después de regularizar (silhouette en los tres conjuntos y estabilidad ante la inicialización).




Figura 7. Estabilidad (ARI promedio) vs. K, antes y después de regularizar. La curva "después" alcanza valores mucho más altos, especialmente cerca de K=5.

La visualización de los clusters finales (PCA 2D) muestra una separación mucho más nítida y consistente entre entrenamiento, validación y prueba:




Figura 8. Clusters del modelo regularizado ($K=5$) en entrenamiento, validación y prueba. Los 5 segmentos (por ingreso y gasto) se mantienen estables y reconocibles en los tres conjuntos.

Como referencia adicional, la curva de convergencia (inercia por iteración) del modelo base confirma que K-means converge en pocas iteraciones, como es esperado:




Figura 9. Curva de convergencia de K-means (inercia por iteración), modelo base.

7. Mejora obtenida y conclusiones

- **Silhouette:** mejora de ~ 0.40 a ~ 0.55 en los tres conjuntos (+37% aprox.), con una brecha train–val–test que se mantiene pequeña (0.537–0.557) antes y después, confirmando que la mejora es de calidad de estructura y no un simple ajuste a un conjunto particular.
- **Estabilidad/varianza:** el ARI promedio entre corridas con distinta inicialización subió de 0.623 a 0.893, es decir, el modelo regularizado converge de forma mucho más reproducible: la mayoría de los clientes reciben el mismo cluster sin importar la semilla aleatoria.

- **Sesgo:** se redujo, ya que el modelo regularizado captura una estructura de segmentos (5 grupos por ingreso/gasto) más clara y con mayor silhouette, sin necesidad de fragmentar en 9 clusters pequeños y poco interpretables.
- **Ajuste final:** el modelo regularizado ($K=5$, PCA 2D, $n_{init}=20$) se ubica en un punto de buen ajuste (fit): silhouette alto y consistente entre los tres conjuntos, y alta estabilidad ante la inicialización, en contraste con el sobreajuste por varianza observado en el modelo base.

En conjunto, este análisis muestra que el desempeño de K-means sobre datos reales no depende únicamente de elegir un buen valor de K , sino también de la calidad y relevancia de las variables utilizadas y de la estabilidad de la solución encontrada. El modelo base, aunque generalizaba de forma aceptable entre entrenamiento, validación y prueba en términos de silhouette (~ 0.40 en los tres conjuntos), presentaba una varianza alta: sus clusters cambiaban considerablemente ante distintas inicializaciones aleatorias ($ARI \approx 0.62$), señal de sobreajuste a ruido y particularidades de la muestra más que a estructura genuina.

Al eliminar la variable Gender (poco informativa), reducir la dimensionalidad con PCA y aumentar el número de inicializaciones (n_{init}), se obtuvo un modelo con mejor silhouette (~ 0.55 en los tres conjuntos) y una estabilidad notablemente mayor ($ARI \approx 0.89$), evidenciando que la regularización y el ajuste de hiper parámetros no solo mejoran las métricas de calidad del clustering, sino también su reproducibilidad y confiabilidad como herramienta de segmentación de clientes.

Referencias

Dataset: Choudhary, V. (Kaggle) — Customer Segmentation Tutorial in Python / Mall Customer Segmentation Data.

<https://www.kaggle.com/datasets/vjchoudhary7/customer-segmentation-tutorial-in-python>

Código base: Rergis Novelo, M. — IA-TC3009C. K-means.

<https://github.com/MichelleRergis/IA-TC3009C.-K-means>

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.